

Oussama Essalehi

+33 7 52 07 31 00 | oussama.essalehi@gmail.com | linkedin.com/oussama-essalehi | github.com/Oussama-essalehi | oussama-essalehi.dev | Toulouse, France

FORMATION

Université Toulouse III – Paul Sabatier

Master MIAE – Ingénierie des Données et Protection (IDP)

Cours : *Data Science, Data Engineering, Machine Learning, Big Data, Gen AI, Cloud & DevOps, Gestion de projet agile, Gouvernance des données*

Sept. 2024 – Août 2026

Toulouse, France

EXPÉRIENCE

Data Analyst

Wewise

Sept. 2024 – Août 2026

Toulouse, France

- Conception et automatisation de tableaux de bord Power BI (DAX) à partir des données de l'ERP, pour le suivi de l'activité, des ventes, des achats et des stocks.
- Création de flux Power Query et automatisation de traitements récurrents via Excel VBA.
- Développement de requêtes SQL Server pour l'extraction, le nettoyage et la consolidation des données de gestion.
- Développement de scripts Python (pandas, numpy) de contrôle qualité : détection des doublons, des valeurs manquantes et des incohérences entre sources.
- Documentation des traitements et des indicateurs, formation ou accompagnement des utilisateurs.

PROJETS

Plateforme de données e-commerce batch & streaming | *Python, Kafka, Spark, Airflow, dbt, PostgreSQL, Great Expectations, Docker*

- Conception de pipelines d'ingestion batch (API et fichiers CSV) et streaming (événements de commandes via Kafka), orchestrés par Airflow avec gestion des reprises et des alertes.
- Structuration d'un Data Lake en architecture médaille (bronze, silver, gold) sur Delta Lake, puis modélisation d'un Data Warehouse en schéma en étoile avec dbt (faits ventes, dimensions clients, produits, temps).
- Mise en place de contrôles qualité automatisés (Great Expectations, tests dbt) : complétude, unicité, fraîcheur des données, avec suivi des anomalies.
- Mise à disposition de data marts pour les usages analytiques (Power BI) et data science (features pour la prévision de la demande).
- Documentation des pipelines, du lignage et des schémas via dbt docs, et conteneurisation de l'ensemble avec Docker Compose.

Analyse de la mobilité urbaine sur Databricks | *Databricks, PySpark, SQL, Delta Lake, MLflow, Power BI*

- Ingestion automatisée des données open data de vélos en libre-service et de météo via un job Databricks planifié, avec stockage brut en Delta Lake.
- Transformation en architecture médaille (bronze, silver, gold) en PySpark et SQL, avec contrôles de qualité intégrés au pipeline.
- Segmentation des stations par clustering et prévision de la fréquentation, avec suivi des expériences dans MLflow.
- Tableau de bord Power BI connecté en direct au SQL warehouse Databricks : fréquentation, disponibilité, effet de la météo, stations saturées.
- Recommandations opérationnelles pour le rééquilibrage des vélos aux heures de pointe.

Assistant IA d'analyse de données en langage naturel | *Python, LangChain, LLM API, RAG, pgvector, PostgreSQL, FastAPI*

- Développement d'un agent IA qui traduit des questions en français en requêtes SQL, les exécute sur une base PostgreSQL et restitue la réponse avec un graphique.
- Mise en place d'un RAG sur la documentation des données (dictionnaire des tables, définitions des indicateurs) avec embeddings Hugging Face stockés dans pgvector, pour fiabiliser la génération des requêtes.
- Évaluation de la qualité des réponses sur un jeu de questions de référence (exactitude des requêtes et des résultats), avec comparaison de plusieurs LLM et variantes de prompts.
- Sécurisation de l'exécution (accès en lecture seule, validation des requêtes) et gestion des erreurs avec correction automatique par l'agent.

COMPÉTENCES TECHNIQUES

Langages : Python (pandas, numpy), SQL, Java, JavaScript

Data Engineering : Spark / PySpark, Kafka, Airflow, dbt, Delta Lake, Databricks, ETL / ELT, Great Expectations

Cloud & DevOps : AWS, Azure, Docker, Git, FastAPI

IA & LLM : scikit-learn, MLflow, Hugging Face, LangChain, RAG, LLM APIs, Streamlit

Bases de données : PostgreSQL, SQL Server, MySQL, MongoDB, Oracle

Visualisation & BI : Power BI (DAX), Power Query, Excel (VBA), Tableau

Langues : Français, Anglais

CENTRES D'INTÉRÊT

Échecs, poker et jeux de stratégie · Course à pied et fitness.